

VIGIAR

DAG, arquitetura e métricas

Carga histórica executada: 2021-2026. Relatório para o grupo de pesquisa, com arquitetura implantada, métricas verificadas da publicação e limites de cobertura das fontes.

Indicador	Resultado
Estado	DAG concluída e objetos GCS validados
Datasets / arquivos	10 datasets / 18 Parquets
Volume comprimido	358,92 MiB
Linhas físicas	18.807.041 somadas entre todas as tabelas; não são pessoas únicas
Casos da fonte	12.506.888 em SUM(qt), reconciliados entre SINAN e notificações
Janela pedida	2021-2026 para fatos configuráveis; referências têm vigências próprias
Conclusão Airflow	08/09 23:43:35 BRT

Versão para consumo


gs://mlab-vigiar-parquet-520032582736/runs/2021-2026/20260909T0220Z/

O prefixo identifica a versão verificada desta execução. As versões anteriores permanecem preservadas. A origem e a definição dos dados são descritas neste relatório.

Interpretação

fat_sinan é uma tabela agrupada por atributos e contém multiplicidade em qt. fat_notificacoes usa agregação mais compacta. Use SUM(qt) para comparar casos; contagem de linhas mede grupos distintos. Não some fatos sobrepostos para calcular uma população ou total de casos.

Arquitetura dos pipelines




Acesso: IAP / OS Login. UI ligada apenas a 127.0.0.1:8080.

Airflow 3.3.1 standalone executa em Compute Engine e2-standard-2: 2 vCPUs, 8 GiB de RAM e disco Standard de 30 GB. Orquestrador e ETLs possuem ambientes Python separados. A publicação durável usa Parquet no Cloud Storage; consultas SQL usam BigQuery.

Camada	Função
Bronze	Arquivos e fontes de origem: CSV CNES mensal, DIEESE, feriados e geometrias; tabelas públicas consultadas no BigQuery.
Silver	Tratamentos de códigos, datas, hashes e vigência; intermediários de alguns pipelines permanecem no disco da VM.
Gold	Dez tabelas analíticas publicadas no GCS; SINAN distribuído em arquivos por partição.
Operação	SQLite de metadados, logs Airflow e systemd; acesso por IAP/OS Login, UI em loopback.
Custo	Uma tarefa ativa; teto 30 GiB/consulta; desligamento automático e streaming limitado.

MVP de uso individual: não há alta disponibilidade ou banco externo de metadados. Prefixos por versão e manifesto melhoram rastreabilidade, mas a DAG ainda não implementa promoção transacional de todas as tabelas. Não foi criado acesso público ao bucket.

DAG e dependências



11 tarefas: 1 validação + 10 pipelines. Concurrency efetiva = 1.

As sete tarefas independentes não formam uma cadeia com ordem garantida.

vigiar_manual_pipeline é uma DAG manual, com `schedule=None` e `catchup=False`. A janela histórica é um parâmetro de uma execução, não um backfill de múltiplas datas lógicas do Airflow. `max_active_runs=1` e `max_active_tasks=1` limitam concorrência; a ordem entre tarefas independentes não é garantida.

A validação inicial verifica runtime, parâmetros e acesso ao bucket. Antes de ETLs reais, grava um objeto exclusivo, lê e compara o conteúdo. `dim_cnes_udh` depende de `dim_cnes` e `dim_udh`. As relações analíticas entre fatos e dimensões exigem validação de chaves, além dessas dependências executáveis.

Parâmetro	Valor
Anos gerais / SINAN	2021-2026 / 2021,2022,2023,2024,2025,2026
Referências	AVS 2010; CNES 202607; DIEESE SCD start_date 2021-01-01
Limites	30 GiB por consulta; timeout ETL 5 h; retries=0
Saída	Prefixo runs/2021-2026/20260909T0220Z

O dry-run executa validação de consultas dos seis pipelines BigQuery e ignora os quatro sem consultas. Ele não garante cobertura da fonte nem substitui verificação dos Parquets publicados.

Inventário e granularidade

Dataset	Linhas	Colunas	Arq.	MiB
dim_calendario	2.191	14	1	0,02
dim_municipios	27.748	94	1	4,23
dim_udh	1.961	6	1	3,67
dim_cnes	631.973	61	1	83,03
dim_cnes_udh	39.980	64	1	9,00
fat_avs	1.961	92	1	0,34
fat_clima	145.450	16	1	1,51
fat_notificacoes	5.458.410	8	1	26,80
fat_sinan	12.493.876	141	9	230,18
fat_dieese	3.491	8	1	0,15

Como as tabelas representam os dados

Calendário: um dia. Clima: município e semana, agregando estações. CNES: estabelecimentos no snapshot mensal. CNES/UDH: estabelecimentos associados espacialmente a UDHs de cinco municípios. AVS: referência IPEA 2010. Municípios: atributos de referência, cuja chave precisa respeitar a granularidade observada. DIEESE: município e observação da cesta básica.

Notificações agrupa sete atributos: data, semana, estabelecimento, classificação, sexo, critério de confirmação e evolução. SINAN agrupa 140 atributos selecionados e acrescenta qt, totalizando 141 colunas.

Cada arquivo foi conferido por MD5 e tamanho contra o objeto correspondente no GCS. Esquemas físicos, contagens e gerações estão no manifesto e nas evidências. A soma de linhas das dez tabelas descreve volume físico e não deve ser usada como indicador epidemiológico.

Cobertura temporal e casos

Partição SINAN	Linhas agrupadas	SUM(qt)	Arquivos
2021	1.009.778	1.010.359	1
2022	1.392.702	1.393.877	1
2023	1.507.363	1.508.653	1
2024	6.460.411	6.466.979	4
2025	1.725.210	1.728.234	1
2026	398.412	398.786	1

Base	Cobertura observada
Calendário	2.191 dias, de 01/01/2021 a 31/12/2026; sem dias faltantes ou extras.
Clima	Semanas iniciadas entre 2020-12-27 a 2026-02-22. Anos retornados: 2020, 2021, 2022, 2023, 2024, 2025, 2026.
Notificações	Datas entre 2021-01-03 a 2026-06-29. Qt total reconciliado com SINAN.
CNES / CNES-UDH	Snapshot 202607; não representa uma série mensal histórica 2021-2026.
AVS / municípios	Referência socioeconômica 2010. UDH é referência geográfica.
DIEESE	2010-01-01 a 2025-03-01; 28 datas não convertidas. start_date define SCD, não filtro de observações.

Partições SINAN usam o ano da fonte. Datas de notificação podem pertencer a outro ano, inclusive fora dos dias de fronteira da semana epidemiológica; essas divergências foram preservadas e quantificadas nas evidências. 2026 é parcial e diferentes fontes têm defasagens distintas.

SUM(qt) nos fatos: SINAN 12.506.888; notificações 12.506.888. A disponibilidade de datas não comprova completude de notificação, representatividade territorial ou ausência de subnotificação.

Qualidade, recursos e reprodutibilidade

Dataset	Chave examinada	Nulos	Duplicados
dim_calendario	data	0	0
dim_udh	id_udh	0	0
dim_cnes	id_cnes	0	0
dim_cnes_udh	id_cnes	0	0
dim_municipios	id_municipio	0	22.183

dim_municipios contém desagregações por UDH e localização. A chave (ano, id_municipio, udh, sexo, raca_cor, localizacao) tem 0 duplicados e 0 linhas com nulos. Repetição de id_municipio isolado não é duplicação da observação; joins devem respeitar essa granularidade.

CNES/UDH possui 0 registros sem UDH correspondente na dimensão e 0 valores UDH nulos no output publicado. Abrange Porto Alegre, Rio de Janeiro, Cuiabá, Recife e Manaus; a DAG usa somente coordenadas existentes e não geocodifica ausências.

Cuiabá foi recuperada nos filtros UDH/CNES-UDH com o código IBGE 5103403 e incluída em AVS. Rio Branco permanece configurado na consulta AVS; a ausência de UDHS na resposta da fonte não foi preenchida artificialmente. O dicionário CNES antigo diverge da separação atual CNES/CNES-UDH; o manifesto registra o esquema efetivamente produzido.

Processamento e custo

A execução durou 18,51 minutos. Foram observados 5,11 GiB de RAM usada na VM e 3,57 GiB como maior RSS amostrado de ETL, com coleta a cada 30 s. As consultas reportaram 4816,44 MiB processados conhecidos; jobs sem essa métrica: 1. A fatura final não foi consultada.

Reprodução e uso

Parâmetros, estados de tarefas, logs resumidos, checksums, gerações, esquemas e métricas por arquivo acompanham a publicação. Para reproduzir: usar o código corrigido, as mesmas competências/anos, dry-run prévio e o mesmo teto de custos; publicar em novo prefixo e repetir a auditoria. Novas consultas podem receber revisões das fontes.

Fontes: código e logs da DAG, BigQuery Jobs API, metadados Parquet, GCS Objects API. Código municipal: <https://www.ibge.gov.br/cidades-e-estados/mt/cuiaba.html> . Custos: <https://cloud.google.com/bigquery/pricing> e <https://cloud.google.com/products/compute/pricing> . Nenhuma linha individual de paciente foi incluída neste documento; ele não foi enviado automaticamente ao grupo.

Cobertura geográfica e associação espacial

Município	UDHs	AVS	CNES com UDH
Porto Alegre	335	335	9.697
Rio de Janeiro	1.136	1.136	22.377
Cuiabá	96	96	2.592
Recife	194	194	3.004
Manaus	200	200	2.310

Redução de registros na associação CNES/UDH

Etapas	Registros
CNES nacional	631.973
Após filtro dos cinco municípios	49.264
Sem coordenadas	6.894
Coordenadas fora dos limites	2
Com coordenadas válidas, sem UDH	2.388
Associação final com UDH	39.980

A associação usa as coordenadas disponíveis e o polígono da UDH. Estabelecimentos sem coordenadas, fora dos limites ou sem associação não aparecem em `dim_cnes_udh`; continuam preservados em `dim_cnes`. A geocodificação externa permaneceu desativada nesta execução.

A cobertura territorial de UDH e AVS é restrita aos municípios selecionados. Os fatos SINAN e notificações usam o recorte temporal da fonte nacional; a tabela de clima depende dos municípios com estações. O recorte analítico do estudo exige joins e filtros explícitos.

A correção de Cuiabá recuperou 96 UDHs e 2.592 registros CNES associados em relação ao resultado anterior à correção. As contagens por município acima foram calculadas nos Parquets desta publicação.