

Operação noturna

Carga histórica 2021-2026

RESULTADO: carga executada com sucesso no Airflow e publicação validada no Cloud Storage. A carga utiliza um prefixo próprio e foi conferida por arquivo. A cobertura disponível das fontes continua sendo diferente de uma série completa para todas as bases.

Indicador	Resultado
DAG	vigiar_manual_pipeline; publish_2021_2026_20260909T0220Z
Janela	2021-2026; dez pipelines selecionados
Execução real	08/09 23:25:04 a 08/09 23:43:35 BRT; 18,51 minutos
Objetos Gold	18 Parquets em 10 datasets; 358,92 MiB
Integridade	MD5 e tamanho dos objetos conferidos contra arquivos locais; gerações registradas
Casos reconciliados	12.506.888 em SUM(qt), igual entre SINAN e notificações
Validação de código	32 testes aprovados no Python 3.11 da VM
VM	TERMINATED

Destino da versão

<gs://mlab-vigiar-parquet-520032582736/runs/2021-2026/20260909T0220Z/>

Os arquivos da tentativa bloqueada e das cargas anteriores foram preservados. As tabelas no novo prefixo foram processadas nesta retomada; os relatórios anteriores ao desbloqueio permanecem em blocked_snapshot para auditoria.

Leitura dos resultados

Sucesso de execução não transforma fontes incompletas em séries completas: CNES é um snapshot 202607; AVS é referência 2010; DIEESE depende do arquivo histórico preservado; 2026 é parcial nos fatos observados. Essas limitações estão detalhadas no relatório de pesquisa.

Incidentes, correções e decisões

Evento	Tratamento e resultado
Publicação inicial	Tentativa interrompida antes da publicação. A nova carga foi executada após validação de acesso, em prefixo próprio, com conferência dos arquivos.
Validação inicial insuficiente	A listagem de bucket não testava a publicação. Foi implantado probe de upload, readback, comparação e limpeza de objeto exclusivo antes dos ETLs reais. Prova de bloqueio e prova de sucesso realizadas.
Cobertura de Cuiabá	Corrigido 5103402 para 5103403 nos filtros UDH e CNES/UDH; Cuiabá incluída em AVS preservando os municípios já configurados. Novos testes cobrem códigos, formatos e filtros. Dry-runs adicionais: 0,01 e 0,18 GiB. Só dim_udh foi reexecutada, antes de CNES/UDH.
CNES / TLS DATASUS	Sondagem encontrou certificado expirado. Usado CSV 202607 preservado na VM; validação TLS mantida. Nenhum novo download sem TLS válido.
Arquivos temporários no reboot	Scripts auxiliares de /tmp foram reenviados. Coletor e auditoria foram preservados em /opt/vigiar/reports para continuidade.

Otimizações e limites mantidos

Reutilização de insumo CNES já obtido, uso de cache BigQuery quando disponível, processamento sequencial e download Arrow limitado. Não houve aumento de VM, concorrência ou teto de bytes. A VM da tentativa bloqueada foi desligada após 12 min 11,94 s; a segunda foi mantida apenas para a carga e a auditoria.

SINAN usa quatro streams, duas páginas na fila e grupos de até 100 mil linhas. A compressão e as partições existentes foram preservadas para manter o comportamento validado. Os timers de 15 minutos após a DAG e de seis horas por boot continuam configurados.

Referência da correção geográfica: <https://www.ibge.gov.br/cidades-e-estados/mt/cuiaba.html> . As mudanças anteriores do usuário foram preservadas.

Tarefas e validação de publicação

Tarefa	Estado	Duração (s)
dim_calendario	success	6,23
dim_cnes	success	470,97
dim_cnes_udh	success	13,21
dim_municipios	success	13,23
dim_udh	success	10,47
fat_avs	success	9,38
fat_clima	success	17,53
fat_dieese	success	6,83
fat_notificacoes	success	22,73
fat_sinan	success	495,57
validate_execution_environment	success	15,57

Verificações concluídas

Os objetos foram listados diretamente na API do GCS. Para cada Parquet: presença, tamanho, hash MD5, geração, atualização posterior ao início da execução, esquema físico e número de linhas. A auditoria se limitou aos objetos do prefixo desta retomada para evitar mistura com arquivos antigos do disco.

A dimensão calendário foi comparada aos 2.191 dias de 2021-2026. Foram inspecionadas nulidade e duplicidade de chaves, vínculos UDH, códigos municipais e cobertura temporal. SUM(qt) de SINAN e notificações foi reconciliado. Duplicidades ou limitações de granularidade observadas constam do relatório científico e não são ocultadas pelo sucesso da DAG.

Dry-run inicial: dryrun_2021_2026_20260909T0200Z (success). Primeira publicação: publish_2021_2026_20260909T0200Z (failed). Novo dry-run: dryrun_2021_2026_20260909T0220Z (success, 39,93 s). Publicação válida: publish_2021_2026_20260909T0220Z.

Recursos, custos e evidências

Métrica	Resultado observado
BigQuery da retomada	13 jobs; acertos de cache: 1; 731.491 slot-ms reportados
Bytes conhecidos	5.050.399.067 processados; 5.056.233.472 faturáveis
Métricas não expostas	Jobs sem bytes processados: 1; sem bytes faturáveis: 1. Valores ausentes não significam zero.
Estimativa BQ conhecida	US\$ 0,02874 antes da franquia, somente bytes informados; não é fatura.
RAM amostrada	Até 5,11 GiB usados pela VM; maior RSS de processo ETL observado 3,57 GiB
Disco amostrado	Mínimo de 23,44 GiB livres; amostras a cada 30 segundos
VM + IPv4 nas duas sessões	Estimativa US\$ 0,0474; 39,46 minutos ligados

Estimativas usam US\$ 6,25/TiB para BigQuery e a premissa operacional do projeto de US\$ 0,067/h para VM + US\$ 0,005/h de IPv4. Não incluem disco, armazenamento, operações GCS, tráfego, impostos, câmbio ou franquias compartilhadas. A fatura final não foi consultada. O job da primeira tentativa acrescentou 10 MiB faturáveis.

As amostras de RAM não constituem pico contínuo medido; picos entre amostras podem ser maiores. O bucket permanece em southamerica-east1 e a VM em us-central1-a, com possível custo de tráfego entre regiões.

Reprodutibilidade

Evidências da execução: parâmetros de publicação e dry-run, recursos, estados de tarefas, objetos, métricas, verificações de qualidade, eventos e jobs BigQuery. O manifesto registra gerações, MD5, esquemas e parâmetros. As evidências das tentativas anteriores permanecem arquivadas.

Referências: <https://cloud.google.com/bigquery/pricing> ; <https://cloud.google.com/products/compute/pricing> ; <https://cloud.google.com/vpc/pricing> ; <https://cloud.google.com/storage/pricing> .